SEDDI



Detección del patrón mínimo repetible en telas utilizando los mapas de activación de las CNNs.

Autor: Vicente Gilabert Maño Tutora: Elena Garcés García Máster Universitario en Visión Artificial Curso 2022/2023

Contenido

- 1. Introducción
- 2. Método propuesto
- 3. Experimentos y resultados
- 4. Tiempos de ejecución
- 5. Auto-tiling demo
- 6. <u>Conclusiones y trabajos</u> <u>futuros</u>

1. Introducción

SEDDI

Digitalizar la industria textil.



Fabricas textiles

Diseñadores de ropa

Tiendas y Compradores finales



Problema abierto y difícil de resolver en el área de síntesis de texturas.

Reducción de memoria, menor tiempo de renderizado. Parte mínima necesaria de una textura (tela) para que pueda repetirse infinitamente.





Selección de telas con patrones repetitivos del dataset de SEDDI. Imágenes utilizadas → 133 RGB (escaneadas).



2017 IEEE Winter Conference on Applications of Computer Vision

Repeated Pattern Detection using CNN activations

Louis Lettry¹, Michal Perdoch¹, Kenneth Vanhoey¹, and Luc Van Gool^{1,2}

 $^1\mathrm{Computer}$ Vision Laboratory, ETH Zürich, 8092 Zürich, Switzerland, $^2\mathrm{KU}$ Leuven, PSI, Kasteelpark Arenberg, 3001 Leuven, Belgium

{lettryl, vanhoey, mperdoch, vangool}@vision.ee.ethz.ch

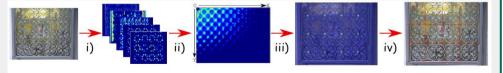


Figure 1. Illustration of our pipeline. i) An image is run through the convolutional filters of a CNN, producing activations that peak at repetitive locations at several scales. ii) A voting scheme defines the most consistent displacement vector on strong activations in the Hough voting space. iii) An Implicit Pattern Model representing the tile is computed and correctly aligned to the repetitions. iv) Instances of repetitive tiles are detected and produce the layout of the grid.

SEDDI



Contents lists available at ScienceDirect

Computers & Graphics (Pre-print)

journal homepage: www.elsevier.com/locate/cag



Automatic Extraction and Synthesis of Regular Repeatable Patterns

Carlos Rodriguez-Pardo^{1,1,*}, Sergio Suja^{1,1}, David Pascual^{1,1}, Jorge Lopez-Moreno^{1,1}, Elena Garces^{1,2,*}

ARTICLE INFO

Article history: Received July 11, 2019

Keywords: Computers and Graphics, Computer vision, Image representations, Interest point and salient region detection, Shape inference, Machine Learning

ABSTRACT

Textures made of regular repeating patterns are ubiquitous in the real world, most notably in man-made environments. They are defined by the presence of a repeating element, which can show a significant amount of random variations, non-rigid deformations or color noise. We propose an end-to-end pipeline capable of finding the size of the minimal repeating pattern in single images, as well as obtaining the single repetition that, when titled, produces the most similar synthesis to the complete image. We do this by combining state-of-the-art algorithms in image transformations, repeating pattern detection, image stitching and deep perceptual losses. Additionally, we show how our pipeline can find the minimal color pattern in woven fabrics, which can be useful for both surface-based render methods and computer vision tasks in the textile domain.

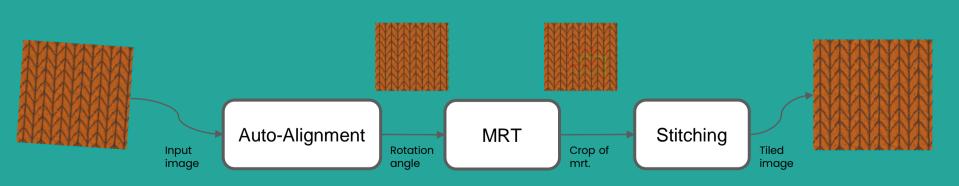
© 2019 Elsevier B.V. All rights reserved.

2. Método propuesto

General pipeline

Se ha propuesto un algoritmo para obtener el mrt con tres etapas:

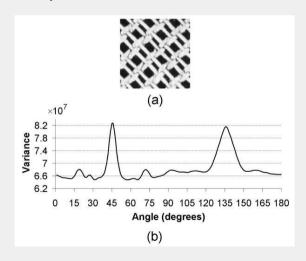
- Auto-alignment.
 - Detección del ángulo de rotación para corregir la imagen de entrada.
- Detección del *minimum repeatable tile (mrt)*.
 - Detectar el recorte mrt.
- Stitching.
 - Corrección del recorte mrt para tratar de evitar costuras (distorsiones) en la imagen tileada.

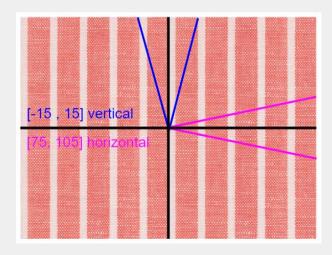


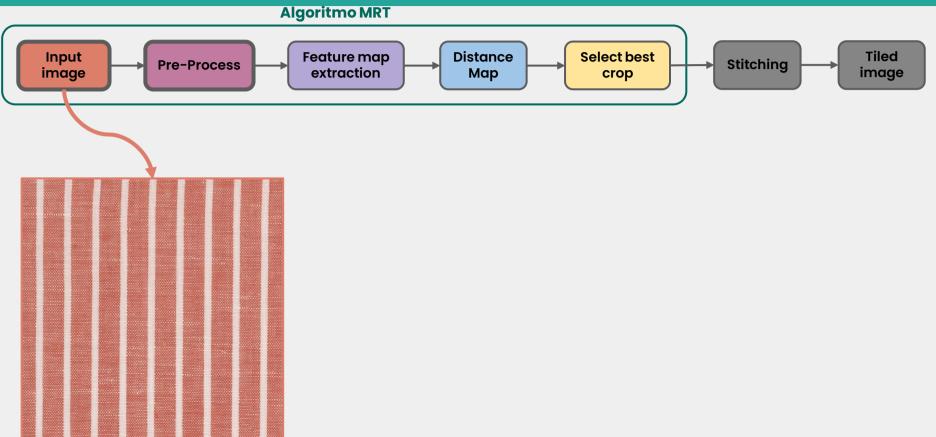
2.1. Auto-alignment

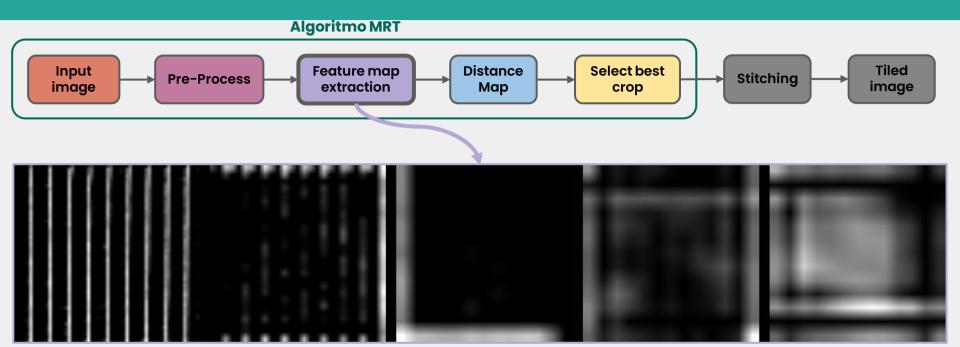
Pasos:

- Filtro laplaciano.
- Transformada de radon 2D en diferentes angulos (-15, 15 y 75, 105).
- Seleccionar el ángulo con una mayor varianza.
- Aplicar matriz de transformación con el ángulo seleccionado.

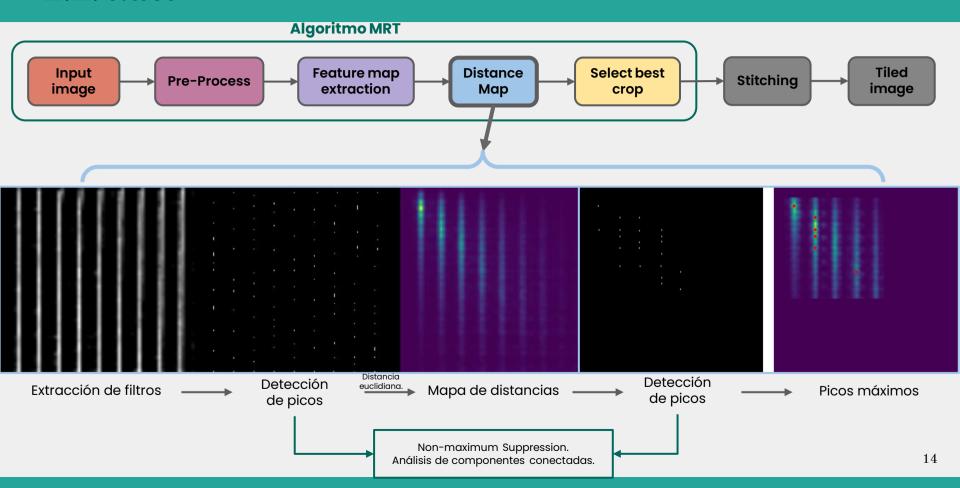


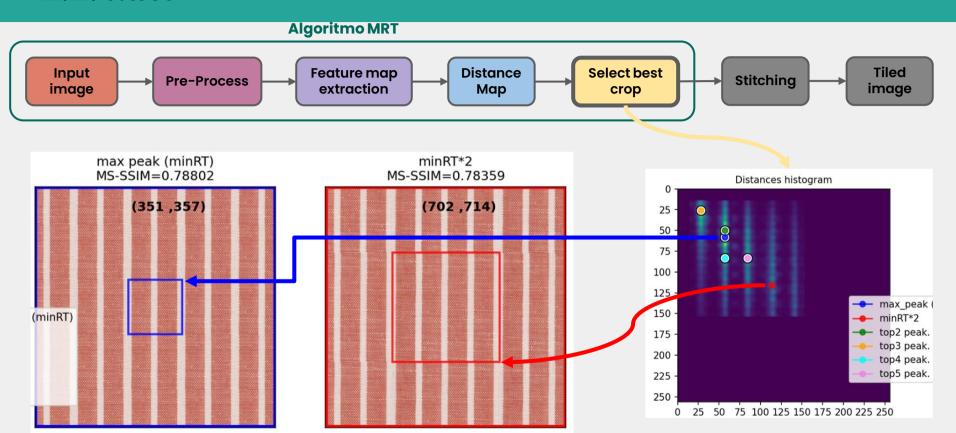




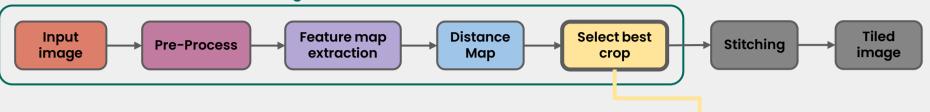


Extracción de los filtros (mapas de activación) de las CNNs. → AlexNet pre-entrenada con ImageNET. Ejemplo aleatorio por capa.





Algoritmo MRT



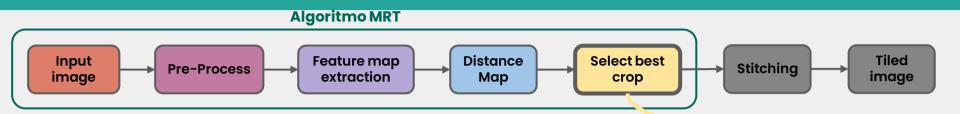
SSIM pipeline Luminance Signal x -Measurement Contrast Luminance Measurement Comparison Contrast Combination Luminance Comparison Signal y Measurement Structure Comparison Contrast Measurement

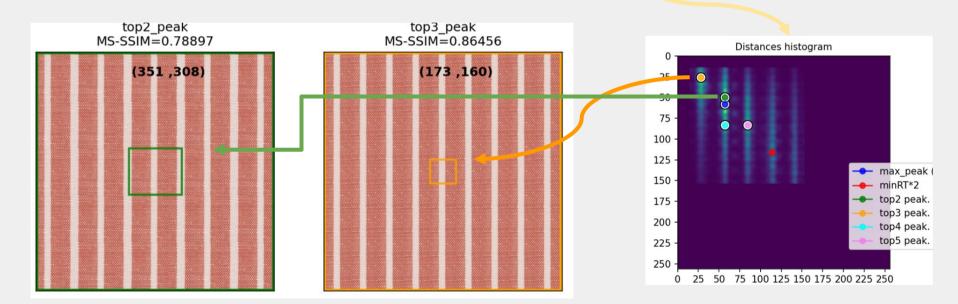
MS-SSIM

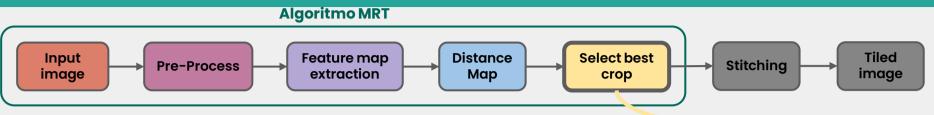
Multi-Scale Structural Similarity Index Measure.

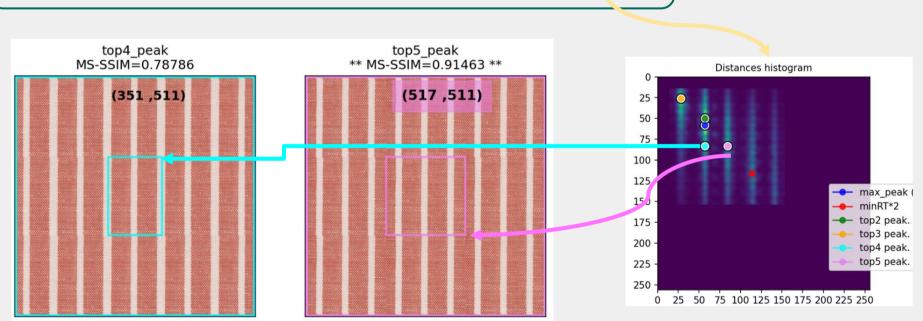
Se obtiene la similitud comparando luminancia, contraste y estructura a diferentes escalas.

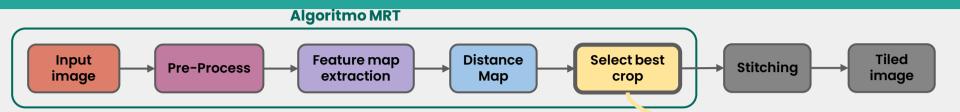


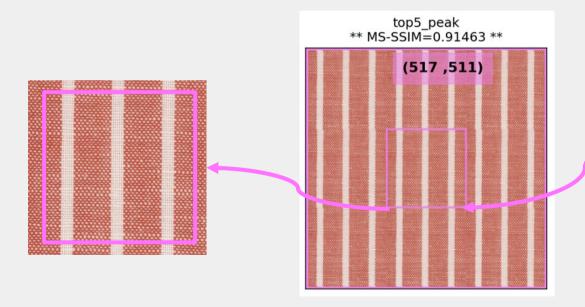


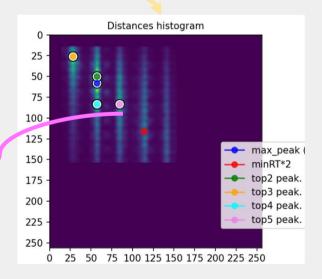










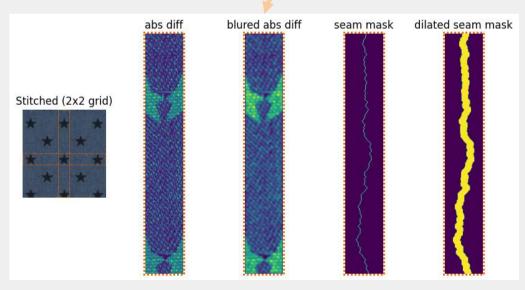


2.3. Stitching

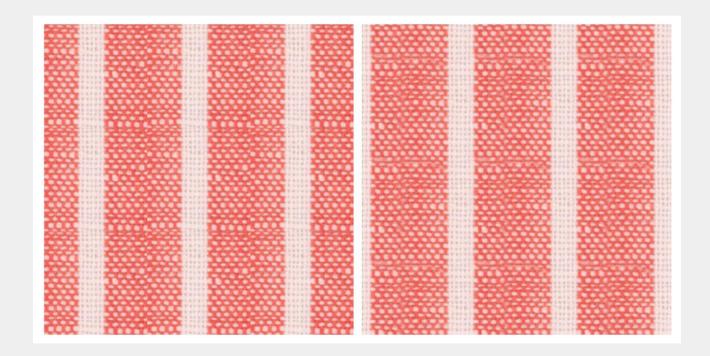


Pasos:

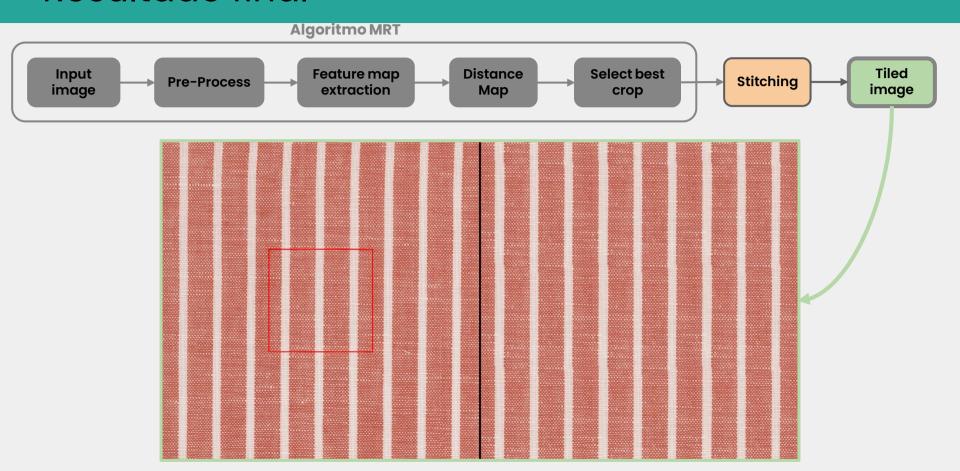
- Repetir el mrt crop con solape 2x2 veces.
- Calcular la diferencia absoluta en el área de solape.
- Filtro gaussiano.
- Obtener la costura de mínima energía → seam carving.
- Dilatar la máscara y aplicar blending.



2.3. Stitching



Resultado final



3. Experimentos y resultados

Evaluación

¿Cómo evaluamos el resultado final?

- **MS-SSIM(original,** *tileada*) \rightarrow [0, 1] \rightarrow cuanto más cerca de 1, mayor similitud.

Problema → Falsos positivos y negativos.

- Resultado no tileable
- Resultado tileable → Poca representación de colores.



Evaluación

Algorithm	Success rate (%)	Error rate (%)	
Auto-tiling	55	45	
MRT	-	15	-
Other	-	30	

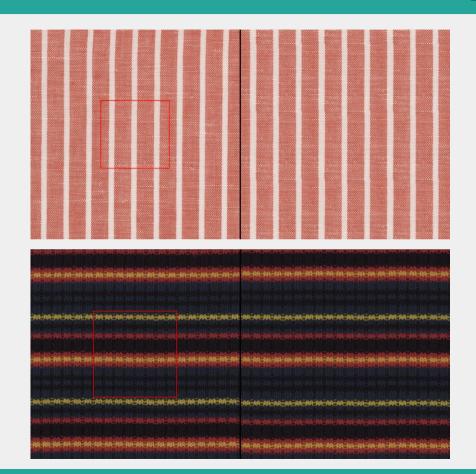
Revisión manual

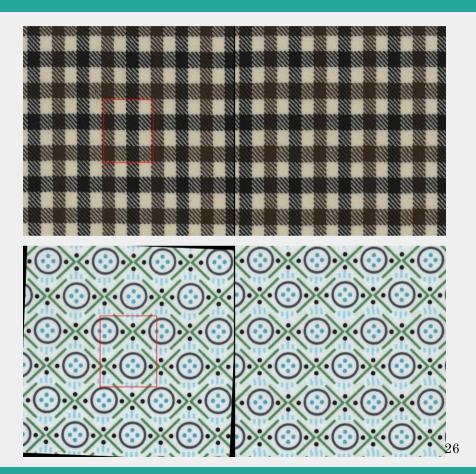
	MS- $SSIM$	After manual review	
threshold	Success rate (%)	Success rate (%)	
0.6	89.5	59.4	-
0.7	78.9	59.4	
0.8	63.9	54.8	

Resultados MS-SSIM con revisión manual

Resultados cualitativos <a>

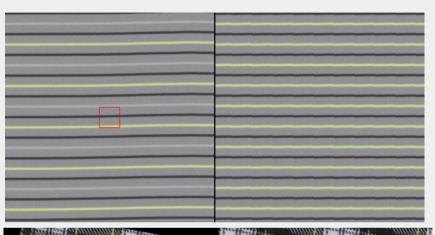


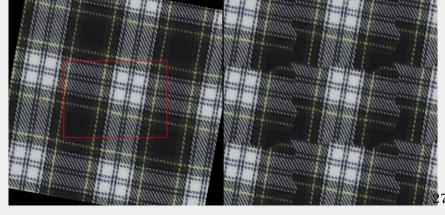




Resultados cualitativos 💥



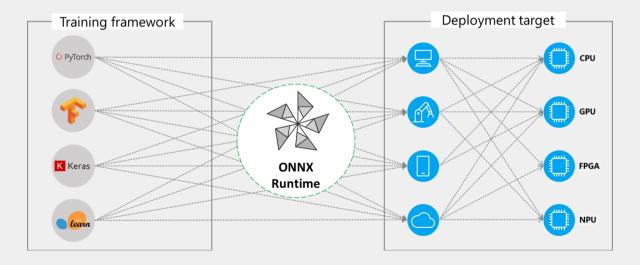




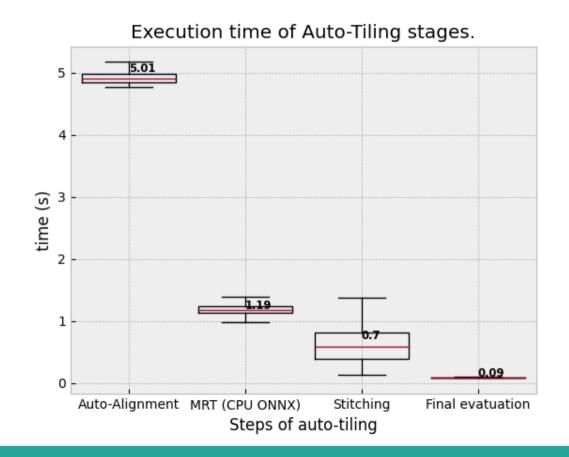
4. Tiempos de ejecución

ONNX y ONNX Runtime

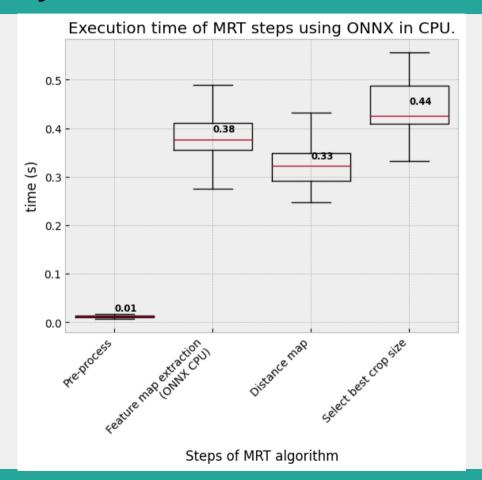
- ONNX → Formato de código abierto para modelos de IA.
 - Interoperabilidad entre plataformas (pytorch, tensorflow, etc.)
- ONNX Runtime → acelerador de modelos de IA multiplataforma.
 - Optimizado para inferencia en diferentes dispositivos (CPU, GPU y dispositivos edge)
 - Permite inferencia en diferentes lenguajes (Python, JS, Java, C++, C, C#, etc).



Tiempo de ejecución

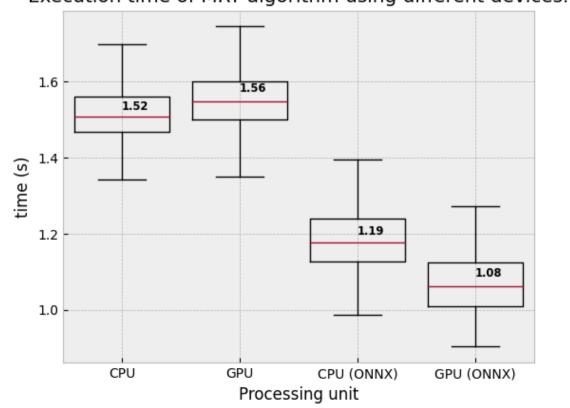


Tiempo de ejecución



Tiempo de ejecución

Execution time of MRT algorithm using different devices.



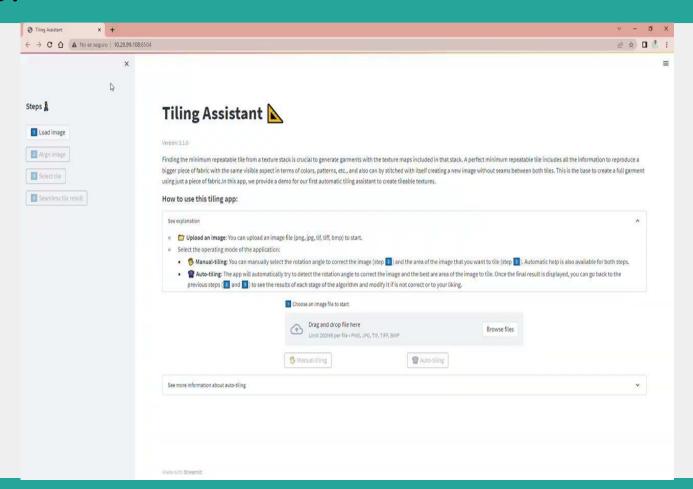
5. Auto-tiling demo

4. Auto-tiling demo

Live demo!

Tools:

- Python
- Streamlit
- ONNX
- Docker



6. Conclusiones y trabajos futuros.

Conclusiones

- Revisión estado del arte.
- Optimización del algoritmo.
- Pruebas del algoritmo en diferentes dispositivos y librerías.
- Resultados muy prometedores para su uso en el mundo real.
 - MRT error → 15 %
 - MRT (segundos) \rightarrow ± 1.2
- Creación y despliegue de la demo para el testeo del algoritmo.

Trabajos futuros

- Auto-alignment.
- Re-entrenar AlexNet con telas.
- Investigar con modelos más avanzados → Diffusion models.
- Estudiar la migración completa al frontend.

¡Gracias!

SEDDI

Autor: Vicente Gilabert Maño

Tutora: Elena Garcés García



Máster Universitario en Visión Artificial

Curso 2022/2023